

UNIVERSIDADE TECNOLÓGICA FEDERAL DO PARANÁ
CURSO DE CIÊNCIA DA COMPUTAÇÃO

**UMA ARQUITETURA MLOPS PARA O CICLO DE VIDA DE
MODELOS DE BIOACÚSTICA: UM ESTUDO DE CASO COM
DADOS DO WIKIAVES**

Seções: Metodologia · Resultados Obtidos · Conclusão

Trabalho de Conclusão de Curso – versão final das seções revisadas

Curitiba, 2026

3 METODOLOGIA

A metodologia deste trabalho foi estruturada em três eixos principais: (i) a criação da base de dados bioacústica a partir da plataforma WikiAves; (ii) o desenvolvimento e treinamento de modelos de Deep Learning para classificação de vocalização de aves; e (iii) a implementação de uma infraestrutura de MLOps para rastreamento, versionamento e experimentação dos modelos. As etapas foram conduzidas de forma incremental e interligada, refletindo o ciclo de vida de um sistema de aprendizado de máquina conforme descrito por Kreuzberger, Kühl e Hirschl (2022).

3.1 BASE DE DADOS

A base de dados deste trabalho foi construída por meio de Web Scraping aplicado à plataforma WikiAves (wikiaves.com.br), repositório colaborativo que concentra registros sonoros de aves brasileiras com alto grau de confiabilidade, dado seu rigoroso processo de curadoria comunitária. O WikiAves disponibiliza, para cada espécie catalogada, metadados acessíveis via endpoints JSON, o que viabilizou a automação do processo de extração.

A seleção de espécies foi restrita à família Columbidae — que engloba pombas, juritis, avoante e espécies correlatas — com o critério de que cada espécie possuísse ao menos 200 gravações disponíveis na plataforma, garantindo um volume mínimo por classe para o treinamento supervisionado. Esse recorte taxonômico resultou em 27 espécies selecionadas.

3.1.1 Extração dos dados

O processo de extração foi implementado no módulo *scrapping/spiderSTFT.ipynb*, desenvolvido em Python com as bibliotecas *requests*, *BeautifulSoup* e *librosa*. O algoritmo consiste em dois estágios: (1) listagem das espécies elegíveis a partir da tabela de espécies da plataforma, que é analisada via parsing HTML e filtrada pelos critérios definidos; (2) download iterativo das gravações em formato MP3 para cada espécie selecionada, com tratamento de erros de acesso e de formatos não reconhecidos.

Após o download, cada arquivo de áudio foi submetido a uma etapa de pré-processamento: reamostrado para uma taxa de amostragem fixa de 44.100 Hz (TARGET_SR), convertido para mono e segmentado em janelas de 5 segundos centradas na região de maior energia sonora, identificada por meio da Energia Quadrática Média (*Root Mean Square Energy*, RMS). Esse critério garante que o trecho com maior atividade acústica seja preservado, eliminando regiões de silêncio ou ruído de fundo.

3.1.2 Análise e preparação dos dados

Cada segmento de 5 segundos foi transformado em espectrograma por meio da Transformada de Fourier de Curto Prazo (*Short-Time Fourier Transform*, STFT), com

parâmetros fixos: $n_fft = 2.048$ e $hop_length = 512$, sem preenchimento implícito ($center=False$). O resultado foi convertido para escala logarítmica em decibéis (dB) e salvo como array NumPy (.npy), produzindo tensores de dimensão $(1.025 \times N_frames)$, em que N_frames corresponde ao número de quadros temporais do segmento.

Para cada espécie foram obtidas até 200 amostras, resultando em um conjunto de 10.794 amostras distribuídas entre as 27 classes. A base foi versionada com o DVC (*Data Version Control*), ferramenta que registra o hash MD5 do diretório de dados (identificado como *4ad1c1b* na versão utilizada nos experimentos), assegurando a reprodutibilidade dos treinamentos.

3.2 ARQUITETURAS DOS MODELOS

Com base na revisão de literatura realizada no Capítulo 2, que aponta as Redes Neurais Convolucionais (CNN) como a abordagem dominante em tarefas de classificação bioacústica e as Redes Convolucionais Recorrentes (CRNN) como alternativa superior para a captura de dependências temporais (Stowell, 2021), dois paradigmas arquiteturais foram investigados neste trabalho: arquiteturas puramente convolucionais e arquiteturas híbridas CRNN.

Todos os modelos utilizam como backbone o ConvNeXt-Tiny pré-treinado (He et al., 2015; Liu et al., 2022), com adaptação da primeira camada de convolução para aceitar entradas monocal (1 canal), em vez dos 3 canais RGB originais. A adaptação é feita pela média dos pesos dos 3 canais, preservando os pesos pré-treinados de ImageNet e acelerando a convergência. A entrada padronizada para todos os modelos é um tensor de dimensão [Batch, 1, Freq, Tempo].

3.2.1 CRNN_ConvNeXt_Tiny_BiLSTM

O primeiro modelo investigado combina o backbone ConvNeXt-Tiny com uma camada recorrente bidirecional (BiLSTM). Após a extração de características pelo backbone (saída: 768 canais), um pooling global é aplicado na dimensão de frequência, produzindo uma sequência temporal [Batch, T_feat, 768] que serve de entrada para a BiLSTM com 2 camadas e 256 unidades ocultas em cada direção. O vetor de contexto é obtido por média temporal e classificado por uma camada linear com Dropout de 0,3.

3.2.2 CRNN_ConvNeXt_Tiny_DeepConv_BiLSTM

O segundo modelo estende o anterior com a inserção de um *neck* convolucional profundo entre o backbone e a BiLSTM. Esse *neck* é composto por três blocos residuais 2D (ConvResBlock) que reduzem progressivamente os canais de 768 para 256 ($768 \rightarrow 512 \rightarrow 384 \rightarrow 256$), refinando as representações espaciais aprendidas pelo backbone antes da etapa recorrente. Cada bloco residual segue a estrutura Conv2d $\rightarrow$ BatchNorm $\rightarrow$ GELU $\rightarrow$

Conv2d → BatchNorm com conexão residual projetada quando necessário.

3.3 TREINAMENTO E CONFIGURAÇÕES EXPERIMENTAIS

O treinamento dos modelos seguiu um protocolo experimental padronizado, descrito a seguir. O conjunto de dados foi dividido de forma estratificada em três subconjuntos: 80% para treinamento, 10% para validação e 10% para teste, com semente aleatória fixada em 42. A estratificação garante que a proporção de cada espécie seja mantida em todos os subconjuntos, evitando viés de seleção.

Hiperparâmetro	Valor
Épocas máximas	50
Batch size	32
Otimizador	Adam
Taxa de aprendizagem	0,0001
Paciência (early stopping)	10 épocas
Delta mínimo (early stopping)	0,0001
Função de perda	Cross-Entropy com Label Smoothing ($\alpha = 0,1$)
Augmentation (prob. por técnica)	0,5

Quadro 1 – Hiperparâmetros de treinamento utilizados nos experimentos. Fonte: autoria própria.

A função de perda Cross-Entropy com Label Smoothing ($\alpha = 0,1$) foi adotada para reduzir o overfitting em classes acusticamente similares, como as da família Columbidae, forçando o modelo a manter um grau de incerteza na distribuição de probabilidade de saída (Szegedy et al., 2016). O *early stopping* monitora a perda de validação e interrompe o treinamento quando não há melhora superior ao delta mínimo por 10 épocas consecutivas, prevenindo o sobreajuste.

3.3.1 Augmentação de Dados

Para aumentar a diversidade das amostras de treinamento e melhorar a capacidade de generalização dos modelos, foi implementado um pipeline de augmentação aplicado exclusivamente ao subconjunto de treinamento. O pipeline aplica seis técnicas em sequência, cada uma com probabilidade independente de 0,5 de ser executada: (1) adição de ruído gaussiano; (2) deslocamento temporal (*time shift*); (3) máscara de frequência (*SpecAugment – frequency masking*); (4) máscara temporal (*SpecAugment – time masking*); (5) ajuste de ganho; e (6) simulação de *pitch shift* por deslocamento vertical das bandas de frequência. Essa abordagem simula variações naturais presentes em gravações de campo, reduzindo a sensibilidade do modelo a condições específicas de captura.

3.4 INFRAESTRUTURA DE MLOPS

A infraestrutura de MLOps foi implementada com foco no rastreamento de experimentos e no versionamento de dados e modelos, correspondendo às práticas do Nível 1 de Maturidade definido pelo Google Cloud (2024). Duas ferramentas principais foram integradas: o MLflow, para rastreamento de experimentos, e o DVC, para versionamento do dataset.

O módulo *mlops/mlflow_config.py* configura o servidor de rastreamento MLflow apontando para o diretório *mlruns/* local. A cada execução de treinamento, o sistema registra automaticamente: os hiperparâmetros do experimento, as métricas por época (perda e acurácia de treinamento e validação), as métricas finais no conjunto de teste (acurácia, precisão, recall e F1-Score), a versão do dataset (hash MD5 extraído do arquivo *dataset.dvc*), o commit Git correspondente ao código, e os artefatos do modelo treinado. Ao final de cada execução, o modelo é registrado automaticamente no MLflow Model Registry.

O versionamento do dataset foi realizado com o DVC, que rastreia alterações no diretório de dados por meio de checksums MD5. O arquivo *dataset.dvc* registra o hash do diretório e é versionado junto ao repositório Git, garantindo a reprodutibilidade dos experimentos ao associar cada execução de treinamento à versão exata do dataset utilizada.

4 RESULTADOS OBTIDOS

Esta seção apresenta os resultados dos experimentos de classificação de vocalizações de aves conduzidos neste trabalho, bem como uma avaliação da infraestrutura de MLOps implementada. Os experimentos foram realizados sobre o dataset de 10.794 espectrogramas STFT distribuídos em 27 espécies da família Columbidae, extraídos do WikiAves.

4.1 RESULTADOS DOS MODELOS DE CLASSIFICAÇÃO

Dois modelos foram levados a resultados completos com relatório de teste: o CRNN_ConvNeXt_Tiny_BiLSTM e o CRNN_ConvNeXt_Tiny_DeepConv_BiLSTM. A Tabela 1 apresenta um comparativo das métricas obtidas no conjunto de teste para ambas as arquiteturas.

Métrica	CRNN-BiLSTM	CRNN-DeepConv-BiLSTM
Épocas treinadas (early stopping)	27	25
Melhor Acc. de Validação	85,08%	86,10%
Acurácia no Teste	85,37%	85,37%
Precisão Ponderada (Weighted)	0,8592	0,8656
Recall Ponderado (Weighted)	0,8537	0,8537
F1-Score Ponderado (Weighted)	0,8542	0,8567
Tempo de Treinamento	01:18:11	01:15:40
Classes (espécies)	27	27

Tabela 1 – Comparativo de desempenho entre as arquiteturas avaliadas no conjunto de teste (27 classes, 1.080 amostras). Fonte: autoria própria.

Ambas as arquiteturas atingiram acurácia de 85,37% no conjunto de teste. O modelo CRNN_ConvNeXt_Tiny_DeepConv_BiLSTM apresentou marginal superioridade em precisão ponderada (0,8656 contra 0,8592) e F1-Score ponderado (0,8567 contra 0,8542), sugerindo que o *neck* convolucional profundo contribui para uma distribuição de acertos mais equilibrada entre as classes, a despeito de não alterar a acurácia global. Ambos os modelos convergiram rapidamente, ativando o *early stopping* antes da 30ª época, com tempo total de treinamento inferior a 1 hora e 20 minutos em GPU.

4.2 ANÁLISE POR CLASSE

A análise das estatísticas por classe no modelo CRNN_ConvNeXt_Tiny_DeepConv_BiLSTM revela uma distribuição heterogênea de desempenho. As classes que atingiram F1-Score perfeito ou próximo de 1,0 incluem a classe 24 (F1 = 0,962) e as classes 1 e 11 (F1 = 0,950), indicando alta discriminabilidade acústica dessas espécies. Em contraste, as classes 18 (F1 = 0,653) e 6 (F1 = 0,700)

apresentaram os maiores índices de confusão, o que pode ser atribuído à semelhança acústica entre espécies da família Columbidae, reconhecida na literatura como um dos principais desafios para sistemas de classificação bioacústica (Sanchez et al., 2021).

Destaca-se que o F1-Score mínimo obtido (0,653) é superior ao registrado por Sanchez et al. (2021) — que reportaram acurácia máxima de 75% em espécies de aves na base NIPS4Bplus — demonstrando que o uso do backbone ConvNeXt-Tiny pré-treinado proporciona vantagem significativa em relação a arquiteturas treinadas do zero sobre bases de menor escala.

4.3 INFRAESTRUTURA DE MLOPS IMPLEMENTADA

A infraestrutura de MLOps foi avaliada qualitativamente segundo os níveis de maturidade definidos pelo Google Cloud (2024). O sistema implementado atinge o Nível 1 de Maturidade, caracterizado pelo rastreamento sistemático de experimentos e pelo versionamento de dados e modelos, mas ainda sem a automação completa do pipeline de CI/CD/CT.

As funcionalidades efetivamente implementadas e validadas durante os experimentos foram: (1) rastreamento automático de hiperparâmetros e métricas por época via MLflow; (2) associação biunívoca entre versão do dataset (hash DVC) e execução de treinamento; (3) versionamento do código via tag Git associada ao run MLflow; (4) geração automática de relatório em PDF com curvas de aprendizado, matriz de confusão e estatísticas por classe; e (5) registro automático do modelo treinado no MLflow Model Registry com versionamento incremental.

As funcionalidades previstas no escopo original do Nível 2 — incluindo o monitoramento contínuo de drift em produção, o acionamento automático de re-treinamento via trigger de novos dados do WikiAves e o pipeline completo de CI/CD — não foram implementadas no prazo deste trabalho, constituindo uma limitação explícita do escopo executado, conforme discutido na Seção 5.

4.4 COMPARAÇÃO COM TRABALHOS RELACIONADOS

Trabalho	Dataset	Classes	Acc. / F1
Sanchez et al. (2021)	NIPS4Bplus	87	≤ 75% (aves)
Este trabalho – CRNN-BiLSTM	WikiAves (Columbidae)	27	85,37% / 0,8542
Este trabalho – CRNN-DeepConv-BiLSTM	WikiAves (Columbidae)	27	85,37% / 0,8567

Tabela 2 – Comparativo com trabalho relacionado de classificação bioacústica de aves. Fonte: autoria própria com base em Sanchez et al. (2021).

5 CONCLUSÃO

Este trabalho apresentou o desenvolvimento de um sistema de classificação de vocalizações de aves brasileiras da família Columbidae, com suporte a uma infraestrutura de MLOps para rastreamento de experimentos e versionamento de dados e modelos. O escopo original propunha a implementação de uma arquitetura de Nível 2 de Maturidade MLOps — com monitoramento de drift em produção, pipeline de CI/CD e re-treinamento automático —, contudo, o escopo foi redimensionado durante a execução do trabalho, em alinhamento com a orientação da banca avaliadora, que indicou a necessidade de delimitar o objeto de estudo para garantir a profundidade e a qualidade científica dos resultados apresentados.

O sistema desenvolvido operacionaliza as seguintes contribuições concretas: (1) a criação de uma base de dados bioacústica de 10.794 espectrogramas STFT de 27 espécies da família Columbidae, extraídos do WikiAves, constituindo um recurso inédito para a avifauna brasileira nesse nível de especificidade taxonômica; (2) a proposição e avaliação de duas arquiteturas de Deep Learning baseadas em ConvNeXt-Tiny, integrando mecanismos recorrentes (BiLSTM) e convolucionais profundos como *neck*, que alcançaram acurácia de 85,37% e F1-Score ponderado de até 0,857 em um cenário com 27 classes; e (3) a implementação de uma infraestrutura de MLOps de Nível 1 de Maturidade, que associa automaticamente cada experimento à versão exata do dataset e do código, promovendo reprodutibilidade e rastreabilidade sistemáticas.

Os resultados demonstram a viabilidade do uso de modelos de Deep Learning com transfer learning para a classificação de vocalizações de aves brasileiras a partir de dados de plataformas colaborativas. O desempenho obtido supera o reportado por Sanchez et al. (2021) para a classificação de aves na base NIPS4Bplus ($\leq 75\%$), reforçando que o uso de backbones pré-treinados e técnicas modernas de augmentação são escolhas metodológicas decisivas para esse domínio.

5.1 LIMITAÇÕES DO TRABALHO

As principais limitações identificadas neste trabalho são: (i) o escopo taxonômico restrito a uma única família (Columbidae), com 27 classes, o que, embora adequado para a prova de conceito, não representa a diversidade da avifauna brasileira; (ii) a ausência de implementação do monitoramento de drift em produção e do re-treinamento automatizado, que constituíam objetivos centrais do escopo original; (iii) a limitação de 200 amostras por espécie imposta pela viabilidade de scraping no período da pesquisa, o que pode subestimar o potencial do método em cenários de maior escala; e (iv) a ausência de avaliação em dados externos ao WikiAves, o que impede generalizações sobre o comportamento do modelo em gravações de campo com condições acústicas distintas.

5.2 TRABALHOS FUTUROS

Os resultados obtidos e as limitações identificadas apontam para um conjunto de direções de pesquisa relevantes, especialmente para continuação em nível de pós-graduação:

Ampliação do escopo e escalabilidade da base de dados. Uma extensão natural deste trabalho é a construção de uma base de dados abrangendo múltiplas famílias taxonômicas da avifauna brasileira — seguindo a tendência de modelos de larga escala como o Perch 2.0 (Merriënboer et al., 2025), treinado em mais de 1,5 milhão de gravações e 10.906 classes. A automação completa do pipeline de extração e processamento, com monitoramento contínuo da plataforma WikiAves, constituiria um sistema de aquisição de dados contínua para alimentar futuros modelos.

Implementação da arquitetura MLOps de Nível 2. O objetivo não alcançado neste trabalho — a implementação de um pipeline com CI/CD/CT e monitoramento de drift — representa uma agenda de pesquisa aplicada de alto valor. A integração de ferramentas como Evidently AI para detecção de data drift, Airflow ou Prefect para orquestração de pipelines, e Kubernetes para deploy escalável constituiria uma contribuição significativa para a área de MLOps aplicada à bioacústica.

Investigação de arquiteturas baseadas em transformers. Modelos como o Audio Spectrogram Transformer (AST) e variantes do Vision Transformer (ViT) aplicados a espectrogramas têm demonstrado desempenho superior a CRNNs em tarefas de classificação de áudio em benchmarks recentes. A comparação sistemática dessas arquiteturas com os modelos propostos neste trabalho, especialmente em cenários de poucos dados por classe (*few-shot learning*), representa uma lacuna relevante na literatura de bioacústica computacional.

Avaliação em dados de monitoramento acústico passivo (PAM). A validação dos modelos desenvolvidos em gravações obtidas por dispositivos de monitoramento acústico passivo implantados em campo — conforme descrito por Darras et al. (2019) — permitiria avaliar a capacidade de generalização real dos sistemas e sua viabilidade como ferramenta de conservação ambiental. Esse tipo de avaliação constitui o passo fundamental para a transição de um protótipo de pesquisa para uma aplicação operacional.

Modelos multiclasse e multi-espécie. O presente trabalho trata a classificação como um problema multiclasse (uma espécie por amostra). Cenários realistas de campo, porém, frequentemente envolvem vocalizações simultâneas de múltiplas espécies, exigindo abordagens de detecção multi-label. A adaptação do pipeline de dados e das arquiteturas para suportar esse cenário constitui uma linha de pesquisa relevante para aplicações de monitoramento de biodiversidade em larga escala.

Em síntese, este trabalho estabelece uma base metodológica e experimental sólida para pesquisas em bioacústica computacional aplicada à avifauna brasileira, com rastreabilidade assegurada pela infraestrutura de MLOps implementada. As contribuições aqui apresentadas, embora de escopo reduzido em relação ao projeto original, constituem um ponto de partida robusto para investigações de maior amplitude e complexidade, especialmente no contexto do mestrado em computação.

REFERÊNCIAS

DARRAS, K. et al. Autonomous sound recording outperforms human observation for sampling birds: a systematic map and user guide. *Ecological Applications*, v. 29, n. 6, e01954, 2019.

DVC. *DVC — Data Version Control*. Disponível em: <https://dvc.org>. Acesso em: 24 nov. 2025.

GASC, A. et al. Assessing biodiversity with sound: Do acoustic diversity indices reflect phylogenetic and functional diversities of bird communities? *Ecological Indicators*, v. 25, p. 279–287, fev. 2013.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. *Deep Learning*. Cambridge: MIT Press, 2016.

GOOGLE CLOUD. MLOps: Continuous delivery and automation pipelines in machine learning. *Google Cloud Architecture Center*. Disponível em: <https://cloud.google.com/architecture/mlops-continuous-delivery-and-automation-pipelines-in-machine-learning>. Acesso em: 21 nov. 2025.

HE, K. et al. Deep Residual Learning for Image Recognition. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016. p. 770–778.

KREUZBERGER, D.; KÜHL, N.; HIRSCHL, S. Machine Learning Operations (MLOps): Overview, Definition, and Architecture. *arXiv*, v. 3, 2022.

LIU, Z. et al. A ConvNet for the 2020s. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022. p. 11966–11976.

MERRIËNBOER, B. V. et al. Perch 2.0: The Bittern Lesson for Bioacoustics. *arXiv*, v. 1, ago. 2025.

MITCHELL, T. M. *Machine Learning*. New York: McGraw-Hill, 1997.

MLFLOW. *MLflow — An open source platform for the machine learning lifecycle*. Disponível em: <https://mlflow.org>. Acesso em: 24 nov. 2025.

MORFI, V. et al. NIPS4Bplus: a richly annotated birdsong audio dataset. *arXiv*, 2018. Disponível em: <https://arxiv.org/abs/1811.02275>.

RUSSELL, S. J.; NORVIG, P. *Artificial Intelligence: A Modern Approach*. 4. ed. New Jersey: Pearson, 2021.

SANCHEZ, F. J. B. et al. Bioacoustic classification of avian calls from raw sound waveforms with an open-source deep learning architecture. *Scientific Reports*, v. 11, n. 15733, p. 1–12, 2021.

SCULLEY, D. et al. Hidden Technical Debt in Machine Learning Systems. In: *Proceedings of the 28th Annual Conference on Neural Information Processing Systems (NeurIPS)*, 2015.

STOWELL, D. Computational bioacoustics with deep learning: a review and roadmap. *PeerJ*, Tilburg, v. 10, dez. 2021.

SZEGEDY, C. et al. Rethinking the Inception Architecture for Computer Vision. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016. p. 2818–2826.

VILLEMEZ, N. R. Machine Learning Operations (MLOPS) Architecture Considerations for Deep Learning with a Passive Acoustic Vector Sensor. Dissertação (Mestrado) — Naval Postgraduate School, 2021.

WIKIAVES. *WikiAves — A enciclopédia das aves do Brasil*. Disponível em: <https://www.wikiaves.com.br>. Acesso em: 23 out. 2025.