

UNIVERSIDADE TECNOLÓGICA FEDERAL DO PARANÁ

Miguel Angelo Larssen Stohr

**Uma Arquitetura MLOps para o Ciclo de Vida de Modelos de Bioacústica:
Um Estudo de Caso com Dados do WikiAves**

PROJETO DE TRABALHO DE CONCLUSÃO DE CURSO

Santa Helena, Paraná
2025

Miguel Angelo Larssen Stohr

**Uma Arquitetura MLOps para o Ciclo de Vida de Modelos de Bioacústica:
Um Estudo de Caso com Dados do WikiAves**

Projeto de Trabalho de Conclusão de Curso apresentado ao Curso de Ciência da Computação da Universidade Tecnológica Federal do Paraná, Câmpus Santa Helena, como requisito parcial à obtenção do título de Bacharel em Ciência da Computação.

Orientador: Prof. Dr. Giuvani Conti

Santa Helena, Paraná

2025

LISTA DE FIGURAS

Figura 1: Implementação dos princípios em componentes técnicos	19
Figura 2: Código HTML da página do WikiAves com destaque nos arquivos de áudio.	25
Figura 3: Fluxo da arquitetura ao trigger de novo dado.	29
Figura 4: Fluxo da arquitetura ao trigger de experimentação do modelo.	30

LISTA DE TABELAS E QUADROS

Quadro 1: Escopo da base de dados deste trabalho comparada a bases conhecidas.	16
Quadro 2: Cronograma de execução das atividades.	33

LISTA DE ABREVIATURAS E SIGLAS

DL: Deep Learning

ML: Machine Learning

IA: Inteligência Artificial

MLOps: Machine Learning Operations

DevOps: Development and Operations

RNA: Rede Neural Artificial

CNN: Convolutional Neural Network

RNN: Recurrent Neural Network

CRNN: Convolutional Recurrent Neural Network

PAM: Passive Acoustic Monitoring

CI: Continuous Integration

CD: Continuous Deployment

CT: Continuous Training

SUMÁRIO

1 INTRODUÇÃO.....	8
1.1 OBJETIVOS.....	9
1.1.1 GERAL.....	9
1.1.2 ESPECÍFICOS.....	10
1.2 CONTRIBUIÇÕES DO TRABALHO.....	10
1.3 JUSTIFICATIVA.....	11
1.4 DELIMITAÇÕES DO TRABALHO.....	11
2 REFERENCIAL TEÓRICO.....	12
2.1 A IA E SUAS TECNOLOGIAS NO CONTEXTO CONTEMPORÂNEO.....	12
2.1.1 Inteligência Artificial (IA).....	12
2.1.2 Machine Learning (ML).....	13
2.1.3 Deep Learning (DL).....	13
2.1.4 Redes Neurais Artificiais.....	14
2.2 BASES DE TREINAMENTO VOLTADAS PARA A BIOACÚSTICA.....	14
2.3 MACHINE LEARNING E A PRESERVAÇÃO DAS ESPÉCIES.....	16
2.4 MLOPS NO CONTEXTO CONTEMPORÂNEO.....	18
2.5 ESTADO DA ARTE.....	20
2.5.1 Machine Learning na Bioacústica.....	20
2.5.2 MLOps no Contexto da Bioacústica.....	22
3 METODOLOGIA.....	23
3.1 BASE DE DADOS.....	23
3.1.1 Extração dos dados.....	24
3.1.2 Análise e preparação dos dados.....	26
3.2 ARQUITETURA DO MODELO.....	26
3.2.1 Deep Learning é fundamental.....	26

3.2.2 ResNet.....	27
3.2.3 CRNN.....	27
3.3 IMPLEMENTAÇÃO DA ARQUITETURA DE MLOPS.....	27
3.3.1 Treinamento Contínuo.....	28
3.3.2 Experimentação do modelo.....	29
3.4 MONITORAMENTO E O FINAL DO CICLO DE VIDA DO MLOPS.....	30
4 RESULTADOS ESPERADOS.....	32
5 CRONOGRAMA.....	33
REFERÊNCIAS.....	34

1. INTRODUÇÃO

O advento da inteligência artificial nas últimas décadas tem se tornado um ponto cada vez mais importante na sociedade, saindo apenas do meio científico e acadêmico, e tomando cada vez mais espaço no cotidiano popular, e não apenas uma presença passiva, mas sim uma força que integra o desenvolvimento humano e sua produtividade material. Agora mais do que nunca o meio da inteligência artificial contempla significativamente o espaço do mercado da computação e de TI, de acordo com a IBM (2023) no Global AI Adoption Index, 42% das empresas de grande porte no mundo todo revelam ter implantado IA em seus negócios, revelando o impacto da IA no mercado corporativo de grande porte.

É fundamental para o desenvolvimento bem-sucedido de qualquer software ou produto digital sua organização e operação, estruturando equipes, versionando recursos como dados, códigos e funcionalidades. Como destacam Feitosa e Fátima (2020), fatores como requisitos claros, objetivos bem definidos, cronogramas realistas, habilidades de gerenciamento e apoio da alta administração são determinantes para o sucesso de projetos de software. Norma esta que, de forma lógica, também se aplica aos recursos e fluxos de trabalho em projetos de Machine Learning (ML).

Nesse contexto, o uso de arquiteturas MLOps (Machine Learning Operations) surge como uma abordagem derivada do DevOps, uma prática que envolve a operacionalização do desenvolvimento do produto de software, e que tem como princípio central a integração contínua entre as equipes de desenvolvimento (Dev) e de operações (Ops). O DevOps busca reduzir barreiras entre essas áreas, promovendo maior colaboração, automação de processos e entrega contínua de software com qualidade e agilidade.

Da mesma forma, o MLOps estende esses conceitos para o universo do aprendizado de máquina, onde os desafios vão além do código. Modelos de Machine Learning dependem fortemente da qualidade e da variabilidade dos dados, além de demandarem ciclos constantes de reavaliação, versionamento e reprocessamento. Assim, o MLOps surge como uma disciplina que une práticas de engenharia, ciência de dados e operações, com o objetivo de tornar o desenvolvimento, o deploy e o monitoramento de modelos mais previsíveis, escaláveis e sustentáveis durante todo o ciclo de vida do desenvolvimento do modelo, envolvendo a coleta, preparação e monitoramento dos dados.

Se debruçando na questão da operacionalização do processo de criação de modelos de Machine Learning, este trabalho busca a criação de uma arquitetura de MLOps para um

modelo de bioacústica, utilizando como demonstração a base de dados do WikiAves, um repositório de aves brasileiras, com rigoroso processo de obtenção dos seus dados, com alta confiabilidade.

A bioacústica, campo que estuda os sons produzidos pelos animais, especialmente pelas aves, constitui uma ferramenta valiosa para compreender ecossistemas, comportamentos e alterações ambientais. As aves são reconhecidas como bioindicadores eficientes, uma vez que suas vocalizações refletem diretamente o estado de conservação de seus habitats, respondendo de forma sensível a variações climáticas, degradação ambiental, desmatamento e interferências antrópicas. A análise dos sons emitidos por diferentes espécies permite não apenas identificar a presença e a abundância de determinadas populações, mas também inferir sobre dinâmicas ecológicas, relações interespecíficas e até mesmo padrões de migração e reprodução (Gasc et al., 2013).

Nesse contexto, o uso de técnicas de inteligência artificial aplicadas à bioacústica representa um avanço significativo para a conservação ambiental. Modelos capazes de reconhecer e classificar automaticamente vocalizações de aves, como o proposto neste trabalho, permitem a coleta e a interpretação de grandes volumes de dados acústicos de forma contínua e não invasiva. Essa abordagem possibilita identificar quais espécies estão presentes em determinada região, acompanhar suas variações populacionais ao longo do tempo e detectar alterações na biodiversidade local com alta precisão.

Ao transformar o som em informação ecológica, a IA contribui para a criação de sistemas de monitoramento automatizados, que auxiliam pesquisadores e gestores ambientais na detecção precoce de ameaças, na delimitação de áreas prioritárias para preservação e no acompanhamento de políticas de conservação. Assim, o uso da inteligência artificial no reconhecimento de vocalizações de aves não apenas potencializa o conhecimento científico sobre a avifauna, mas também reforça o papel da tecnologia como aliada na manutenção do equilíbrio ecológico e na proteção dos ecossistemas naturais.

1.1. OBJETIVOS

1.1.1. Objetivo Geral

Propor, desenvolver e avaliar uma arquitetura de Machine Learning Operations (MLOps) para automatizar o ciclo de vida de modelos de aprendizado de máquina para classificação de

sons de aves, demonstrando a viabilidade, eficiência e robustez desta abordagem para sistemas de bioacústica em produção.

1.1.2. Objetivos Específicos

Estudar e entender os desafios, e as arquiteturas de referência da área da MLOps.

1. Criar a base de dados da bioacústica das aves, realizando um WebScrapping da plataforma da WikiAves.
2. Obter um modelo de Machine Learning dos sons das aves disponíveis no repositório.
3. Implementar um protótipo funcional da arquitetura de MLOps que seja capaz de operacionalizar o desenvolvimento do modelo.
4. Desenvolver e integrar um módulo de monitoramento para avaliar a performance do modelo em produção, capaz de detectar degradação e acionar gatilhos para o re-treinamento automático, fechando o ciclo de MLOps.
5. Analisar os resultados obtidos da arquitetura criada, avaliando sua eficácia nos termos de automação, discutindo o potencial e o uso futuro do sistema desenvolvido.
6. Analisar a acurácia e eficácia do modelo de ML obtido, discutindo também os potenciais do modelo criado para trabalhos futuros.

1.2. CONTRIBUIÇÕES DO TRABALHO

O desenvolvimento de uma arquitetura de MLOps no contexto da bioacústica das aves contribui com o preenchimento de uma lacuna no contexto acadêmico de bioacústica uma vez visto a escassez de trabalhos acadêmicos deste nicho em pesquisas nos repositórios tradicionais. Este nicho de pesquisa acadêmica possui um potencial importante no contexto do MLOps, podendo impulsionar o desenvolvimento de mais ferramentas de ML voltadas

para a acústica de outros seres vivos além das aves através da metodologia proposta por este trabalho.

Assim como o contexto do MLOps na bioacústica, também é escasso trabalhos acadêmicos que visam explorar a rica e vasta base de dados do WikiAves para propósitos voltados à ciência da computação e inteligência artificial, sendo uma plataforma de contribuição e submissão pública de aves presentes no território brasileiro, um modelo de ML sobre esses dados também pode trazer contribuições para a conservação de espécies e melhor entendimento da avifauna brasileira, como é desenvolvido melhor no capítulo de referencial teórico deste trabalho.

1.3. JUSTIFICATIVA

Neste trabalho de conclusão a principal área emergente do tema é o campo da inteligência artificial, estendendo as suas metodologias no campo do MLOps, uma área inerente ao campo da inteligência artificial com pontos mais aprofundados nas metodologias de desenvolvimento, DevOps e automação. Dentro do contexto das áreas definidas pelo CNPq, este trabalho se enquadra na área de Engenharia de Software, visto que o trabalho se volta primariamente na criação primordialmente de uma arquitetura a partir disso tangencia outras áreas como arquitetura de sistemas da computação ou sistemas de informação

1.4. DELIMITAÇÕES DO TRABALHO

Este projeto visa construir um sistema de MLOps voltado para modelos de bioacústica, utilizando como base de dados o repositório de submissão pública brasileiro WikiAves. O escopo principal da proposta é a criação da arquitetura de MLOps dentro do nível 2 de maturidade, além disso, este trabalho também foca na eficiência do modelo de DL e na base de dados que serão criados, buscando sua acurácia e precisão através da arquitetura proposta.

É importante constatar como delimitação deste trabalho, o aspecto de proteção de direitos autorais da plataforma da WikiAves, que impedem o escopo deste projeto ser ainda maior e contribuir ainda mais com a literatura do MLOps na bioacústica, como a divulgação pública da base de dados que será criada.

2. REFERENCIAL TEÓRICO

2.1. A IA E SUAS TECNOLOGIAS NO CONTEXTO CONTEMPORÂNEO

O advento da Inteligência Artificial (IA) nas últimas décadas, de acordo com uma publicação da IBM (2023), tem se consolidado como um ponto crucial no cenário tecnológico, contemplando significativamente o espaço do mercado da computação e de TI. ocupando mais e mais espaço na vida cotidiana, sendo tema recorrente no entretenimento, além da IA ser um campo muito presente em diversas plataformas acessadas diariamente, sendo o exemplo mais comum, os próprios algoritmos de recomendação, como o da Netflix, Spotify, Youtube, Instagram etc.

Para uma contextualização mais objetiva do que é o MLOps, é importante ir além do senso comum sobre o que é a Inteligência Artificial, e também as suas sub-áreas, muitas vezes citadas e também de plena importância para este texto, sendo estas o Machine Learning e o Deep Learning.

2.1.1. Inteligência Artificial (IA)

A Inteligência Artificial é um campo da ciência da computação dedicado ao estudo e à construção de agentes capazes de perceber o ambiente e agir de forma racional. Russell e Norvig afirmam que: “O objetivo da IA é construir agentes que pensam racionalmente. Em outras palavras, agentes que fazem a coisa certa, dado ao que eles sabem” (Russel; Norvig, 2021, tradução nossa).

Em uma perspectiva introdutória, a IA pode ser compreendida como o desenvolvimento de sistemas que, a partir de percepções, conhecimento e métodos de raciocínio ou aprendizado, são capazes de tomar decisões adequadas em situações diversas. Essa capacidade de usar dados, regras e modelos para escolher ações, muitas vezes por meio de processos de inferência ou aprendizado, o que constitui o ponto de partida para o desenvolvimento de sistemas mais complexos e autônomos (Russel; Norvig, 2021).

Em sua essência, a IA busca simular o comportamento inteligente, permitindo que máquinas aprendam, raciocinem, percebam e tomem decisões. Essa simulação é o que permite que a IA englobe uma variedade de tecnologias e métodos algorítmicos que visam a resolução de problemas complexos (Trindade; Oliveira, 2024).

Essa perspectiva de agente racional é fundamental para o desenvolvimento de sistemas de IA aplicados, como os utilizados na bioacústica, onde o sistema deve processar dados sonoros e tomar decisões sobre a classificação de espécies ou a detecção de eventos. Embora o conceito seja amplo, a IA moderna engloba uma variedade de tecnologias e métodos algorítmicos que visam a resolução de problemas complexos (Trindade; Oliveira, 2024).

2.1.2. Machine Learning (ML)

O aprendizado de máquina (Machine Learning) constitui um subcampo da Inteligência Artificial dedicado ao desenvolvimento de métodos que permitem que sistemas computacionais melhorem seu desempenho em determinada tarefa com base na experiência. Em termos formais, Mitchell (1997) define que: “um programa de computador aprende com uma experiência E, em relação a uma classe de tarefas T e a uma medida de desempenho P, se seu desempenho nas tarefas em T, conforme mensurado por P, melhora com a experiência E.” (Mitchell, 1997, tradução nossa).

Essa formulação evidencia que o cerne do aprendizado de máquina não está apenas na execução de algoritmos, mas na capacidade de utilizar dados passados para aprimorar futuros comportamentos. Assim, modelos de ML podem identificar padrões, ajustar parâmetros internos e realizar previsões mais eficazes conforme novas informações são incorporadas, constituindo um dos elementos fundamentais para a construção de sistemas inteligentes modernos.

2.1.3. Deep Learning (DL)

O aprendizado profundo (Deep Learning) é um subcampo do aprendizado de máquina que utiliza arquiteturas compostas por múltiplas camadas de processamento para aprender representações hierárquicas dos dados, conhecidas como Redes Neurais.

Essa metodologia de aprendizado permite que os modelos identifiquem padrões complexos diretamente a partir de grandes volumes de informação, sendo fundamental nos avanços mais recentes do campo da computação, inerentes à algoritmos de reconhecimento de imagem, reconhecimento de fala e texto, além de, sua importância significativa nas IA's generativas, tecnologia esta, que diferente da IA convencional, que aprende padrões, a generativa os reproduz.

O Deep Learning tem o potencial de identificar padrões mais complexos, organizados em múltiplas camadas de um dado, como o rosto de uma pessoa que tem camadas de complexidade que pode se dividir em: nariz, boca, olhos. (Goodfellow; Bengio; Courville, 2016).

Essa capacidade de construir abstrações progressivamente mais complexas explica por que modelos profundos superam métodos tradicionais em diversas tarefas, especialmente quando há grande disponibilidade de dados e capacidade computacional.

Além disso, uma característica marcante das redes neurais profundas é seu funcionamento “caixa-preta”, pois embora esses modelos apresentem alto desempenho, o processo interno pelo qual chegam às suas conclusões é difícil de interpretar devido ao grande número de camadas e parâmetros envolvidos. Em contraste, métodos tradicionais de Machine Learning, como modelos lineares ou árvores de decisão, possuem estruturas mais transparentes e permitem compreender mais facilmente como as variáveis influenciam o resultado. Essa dificuldade de interpretabilidade em redes profundas é amplamente discutida por Goodfellow, Bengio e Courville (2016).

2.1.4. Redes Neurais Artificiais

As Redes Neurais Artificiais (RNAs) constituem um modelo computacional inspirado, ainda que de forma simplificada, no funcionamento do cérebro humano. Elas são formadas por unidades chamadas neurônios artificiais, organizados em camadas interconectadas, capazes de aprender padrões por meio do ajuste de pesos e funções de ativação. (Goodfellow; Bengio; Courville, 2016).

O aprendizado ocorre à medida que esses pesos são atualizados com base no erro cometido pelo modelo, permitindo que a rede generalize padrões presentes nos dados. Esse mecanismo torna as RNAs a base estrutural de muitos métodos modernos, incluindo o próprio Deep Learning, que se vale de redes com grande profundidade e capacidade expressiva.

2.2. BASES DE TREINAMENTO VOLTADAS PARA A BIOACÚSTICA

O entendimento da NIPS4Bplus e de outras bases de dados voltadas a bioacústica é fundamental para a execução desta monografia, podendo ser utilizada como modelo para a construção de uma base de dados extraindo áudios do WikiAves como está proposto por este

trabalho de conclusão de curso, seguindo o método científico e trabalhando sobre a base citada.

A base de dados em questão, é muito utilizada em diversos artigos sobre o tópico de detecção de bioacústica como nos trabalhos de Anderson Harte, Kenndy (2021), Sun et al. (2022), Guei et al. (2023). Este dataset é muitas vezes utilizada como base de treino, e parte disso se dá ao fato de que a NIPS4Bplus, segundo os autores é a primeira base de dados com tags de espécies de pássaros e anotações temporais: “Nesse artigo, nós introduzir o NIPS4Bplus, o primeiro dataset ecológico de áudios que contém tags de espécies de pássaros e anotações temporais.” (Morfi et al., 2018). Ou seja, é uma base de dados que contém as espécies dos pássaros com as suas devidas tags, e também suas marcações de tempo dentro do intervalo do arquivo de áudio.

Segundo Morfi et al (2018), os dados são representados por 687 gravações, e foram coletados em partes de Espanha e da França, podendo se concluir que a base, apesar de muito usada, contém uma variedade muito endêmica de espécies de pássaros, apenas presentes próximas do litoral mediterrâneo dos países citados, o que pode demonstrar a escala e o escopo da base de dados proposta para extração neste trabalho, que trata de uma plataforma de aves brasileiras, sendo o Brasil, um dos países com a maior biodiversidade de aves no mundo.

No artigo, os autores também destacam, além da presença dos pássaros, a presença de outras espécies que convivem com algumas destas aves, sendo estas 7 insetos e 1 anfíbio, e além destes, há a presença de 100 sons de fundo sem a presença de qualquer som de ave, dos 687 coletados, inclusão esta necessária para o aperfeiçoamento de possíveis modelos que viriam a treinar com a base, para o entendimento de sons sem quaisquer presença de pássaros.

Na mesma linha das bases de dados do WikiAves e do NIPS4Bplus, há o Perch 2.0 de Merriënboer et al. (2025), que demonstra a tendência de modelos de bioacústica de alta performance serem treinados em conjuntos de dados massivos e multi-taxa. O Perch 2.0, por exemplo, foi treinado em uma combinação de quatro grandes fontes de áudio rotuladas, incluindo Xeno-Canto e iNaturalist, totalizando mais de 1,5 milhão de gravações e quase 15 mil classes diferentes, abrangendo aves, anfíbios, insetos e mamíferos (Merriënboer et al. 2025).

Essa abordagem de escala e diversidade contrasta com a base NIPS4Bplus, mais focada em espécies endêmicas e com um volume de dados significativamente menor, e reforça a importância de bases de dados abertas e colaborativas, como o WikiAves, para a construção de modelos robustos e generalizáveis.

Quadro 1: Escopo da base de dados deste trabalho comparada a bases conhecidas.

Base de Dados	Nº de Áudios	Classes (Espécies)	Região
NIPS4Bplus	687	87	Europa
WikiAves (extraída)	6.000.000<	1.972	Brasil
Perch 2.0 (DeepMind)	1.367.553	10.906	Global

Fonte: Merriënboer et al. (2025), Morfi et al (2018)

A utilização de fontes como o Xeno-Canto e o iNaturalist pelo Perch 2.0, que são repositórios de ciência cidadã, valida a premissa deste trabalho de que dados de plataformas colaborativas podem ser a espinha dorsal para o desenvolvimento de modelos de bioacústica, especialmente em regiões de alta biodiversidade como o Brasil, onde a curadoria de dados em larga escala é um desafio constante

Em 2025, a página do WikiAves (2025) tem mais de 6 milhões de registros e quase 2000 espécies registradas, estas apenas as que são ocorrentes no Brasil, sendo assim, as aves não são necessariamente endêmicas, a plataforma possui aves que ocorrem em outros lugares das América do Sul, e mesmo em outros continentes no caso das espécies migratórias, e também nem todas as aves registradas são especialmente da natureza brasileira, aves invasivas também estão presentes na plataforma.

O WikiAves conta também com um sistema de inteligência artificial, disponível apenas para contribuidores, logo suas informações não são tão acessíveis, no entanto é conclusivo que o modelo apenas é relacionado com imagens de aves, outro fato é que os dados do WikiAves, apesar de públicos, não possuem ainda um arquivo público que possa ser baixado e manipulado para fins de estudo e pesquisa, como também não possui uma API pública para pesquisas e implementação com software direto, este trabalho, no entanto, se propõe à criação de uma base de dados própria composta por áudios de aves extraídos do WikiAves, devidamente organizados e rotulados, para o avanço de pesquisas em bioacústica e aprendizado de máquina aplicados ao monitoramento da fauna brasileira.

2.3. MACHINE LEARNING E A PRESERVAÇÃO DAS ESPÉCIES

Daleffi (2024) desenvolve um estudo que integra Ecologia Acústica e Ciência de Dados com o objetivo de analisar a paisagem sonora do Cerrado e identificar como diferentes formações ecológicas podem ser reconhecidas a partir de seus padrões acústicos. Para isso, o autor coletou dados por meio de gravadores autônomos instalados em campo, captando sons ambientais em múltiplos pontos do bioma, e organizou essas gravações em um conjunto de dados estruturado para posterior processamento e análise. A partir desses registros, buscou compreender como características acústicas podem refletir a composição e a estrutura dos ambientes, contribuindo para a interpretação ecológica das áreas estudadas. Ao final, Daleffi (2024) conclui que o uso de dados acústicos aliado a métodos computacionais pode fortalecer estratégias de monitoramento e conservação, oferecendo suporte importante para a preservação de biomas ameaçados e da biodiversidade do Cerrado (Daleffi, 2024).

Além do artigo do Daleffi (2024), uma publicação no fórum do Google Deepmind (2025) reforça a importância do desenvolvimento de modelos de Machine Learning para a conservação das espécies, e nesse caso, a matéria foca especialmente em uma espécie de ave, um exemplo que se encaixa com o escopo deste trabalho. O DeepMind é a divisão de inteligência artificial do Google, fábrica que desenvolveu modelos de importância ímpar para o mercado moderno de IA, dentre estes, o Veo 3 de vídeo, e a LLM Gemini.

Segundo o DeepMind, o modelo de IA voltado para identificação de bioacústicas de aves, o Perch, tem sido essencial para a conservação das espécies, ajudando em pesquisas da área, segundo o artigo: “Pesquisas recentes também descobriram que a versão anterior do Perch pode ser usada para identificar aves individualmente e rastrear a abundância populacional, potencialmente reduzindo a necessidade de estudos de captura e soltura para monitoramento das populações” (Deepmind, 2025, tradução nossa).

Outra constatação importante dessa publicação do Deepmind também se relaciona com a conservação de espécies na Austrália:

O Google DeepMind (2025) destaca ainda que o Perch está auxiliando o BirdLife Australia e o Australian Acoustic Observatory na construção de classificadores para diversas espécies únicas da Austrália, e que essas ferramentas inclusive possibilitaram a descoberta de uma nova população da rara Plains Wanderer (DEEPMIND, 2025, tradução nossa).

Sharma, Sato e Gautan (2023) realizaram um estudo de revisão metodológica de monitoramento de habitats naturais a com inteligência artificial, nele os autores discutem a prática de monitoramento de bioacústica em regiões florestais, trazendo neste trecho

afirmações interessantes a respeito do uso da IA's na detecção de bioacústica para a preservação de espécies. Os autores constataam que em regiões florestais o monitoramento por áudio é mais efetivo que o monitoramento visual, uma vez que a visibilidade pode ser obstruída pela vegetação mesmo para animais próximos à câmera, diferentemente de dispositivos de detecção sonora, que podem ouvir distâncias maiores do que uma câmera poderia enxergar:

Esses sons contêm informações valiosas sobre a identidade, o estado, o tamanho e os possíveis perigos relacionados às criaturas. Além disso, as vocalizações podem ser ouvidas a partir de diferentes direções, através de barreiras e por longas distâncias. Dessa forma, monitorar a vida selvagem por meio do som é mais eficaz do que a observação visual.(Sharma; Sato; Gautam, 2023, tradução nossa)

Os autores também afirmam sobre a eficiência de detectores acústicos em monitorar as espécies de uma forma não invasiva, contudo, esse método pode gerar horas e horas de áudio, trazendo uma dificuldade de pesquisa para ouvir todas essas horas e catalogar todos os sons, podendo até mesmo ter longos períodos de absoluto silêncio, dessa forma, a IA pode vir como uma solução para essas metodologias de monitoramento, tendo potencial de reduzir o tempo total para o estudo direto dos áudios, dessa forma, a IA pode trazer resultados como os já citados antes DeepMind (2025) e de Daleffi (2024).

2.4. MLOPS NO CONTEXTO CONTEMPORÂNEO

Sculley et al.(2015) elabora que há uma *dívida técnica* invisível nos modelos de Machine Learning, diferente de uma dívida convencional, a dívida técnica é um custo que se estende ao tomar decisões rápidas, seja para se adequar ao mercado ou atender necessidades de clientes, visto que em determinados momento do ciclo de vida de um software certas modificações e decisões são feitas de formas repentinas. De acordo com Mucci (2025) dívida técnica é o resultado dessas decisões e modificações, que podem afetar a eficiência e otimização de um sistema de software, causando problemas estruturais que se acumulam ao longo do tempo, derivadas de improvisações durante o desenvolvimento, soluções temporárias que nunca voltam a ser revisitadas, assim essa dívida se torna um “gasto futuro”, uma projeção que em prol de uma solução rápida ou mesmo imediata, mas que coloca em detrimento a estrutura do sistema.

De acordo com Sculley et al.(2015), essa dívida técnica tem uma capacidade especial para surgir em sistemas de IA, sendo mais difíceis de detectar pois estes problemas existem no “sistema” do modelo de Machine Learning, ou seja, algo que vai além do código. Os autores também colocam que formas tradicionais de solucionar dívidas técnicas podem não ser eficientes quando se trata de um modelo de ML, visto que estes não só têm problemas de código mas como também de base de dados.

Nesse contexto, surge a prática do MLOps: um conjunto de métodos, arquiteturas e fluxos de trabalho que busca justamente enfrentar os desafios impostos pela dívida técnica em sistemas de Machine Learning. O MLOps propõe a automação de pipelines de treinamento e implantação, o versionamento rigoroso de dados e modelos, o monitoramento contínuo de desempenho e drift, além de práticas de reprodutibilidade e governança que reduzem a fragilidade estrutural desses sistemas.

Kreuzberger, Kuhl e Hirschl (2022) definem a arquitetura e a definição de o que é MLOps, e dentro desses estabelecimentos, existem os conceitos de princípios e de componentes técnicos do MLOps, sendo os princípios a manifestação de uma verdade básica, de um conceito primordial do que deve ser o MLOps, e a partir destes princípios, são construídos os componentes técnicos, que o autor descreve de forma detalhada.




Figura 1: Implementação dos princípios em componentes técnicos.

Fonte: Kreuzberger, Kuhl e Hirschl (2022).

Dessa forma, o MLOps atua como uma camada organizadora que estabiliza o ciclo de vida completo do modelo, garantindo que a evolução contínua do sistema não amplifique a dívida técnica, mas sim a mantenha sob controle por meio de processos sistemáticos.

Em um artigo do Google Cloud (2024), existe uma série de passos dedicados à construção de uma arquitetura de Machine Learning, trazendo definições e boas práticas para projetos de MLOps, além de também definir níveis de maturidade destes sistemas, que podem se mostrar uma ótima métrica para medir os objetivos e o desempenho deste trabalho acadêmico.

Os passos citados no artigo em questão, se referem ao processo da ciência de dados para a construção de um modelo de ML, estes seriam: Extração de dados, Análise dos dados, Preparação dos dados, Treinamento de modelo, Avaliação do Modelo, Validação do modelo, Exibição do modelo e Monitoramento do modelo. Esses passos são importantes para a definição da metodologia deste trabalho, e também são os passos que devem ser automatizados para se atingir níveis satisfatórios de maturidade de MLOps que vão do 0 ao 2 Google Cloud (2024). Resumidamente:

- O nível 0 de maturidade, é o nível onde não são automatizados nenhum dos processos de construção do modelo.
- O nível 1 já tem um treinamento contínuo do modelo, porém ainda com a automação do ciclo de vida do modelo sendo totalmente manual.
- O nível 2, agora tem um ciclo de vida automatizado, com um CI/CD automático, permitindo o ajuste rápido e teste fácil e hiperparâmetros, permitindo a exploração de ideias dentro do modelo.

2.5. ESTADO DA ARTE

2.5.1. Machine Learning na Bioacústica

De acordo com Stowell (2021), uma variedade de taxonomias de animais já tiveram sua bioacústica estudada através de modelos de Deep Learning, sendo a majoritária dessas taxonomias as aves, Stowell (2021) selecionou pelo menos 65 artigos contendo estudos no

campo dos sons emitidos pelas aves, o autor também elucida outros grupos mais estudados seguintes depois das aves, como cetáceos, morcegos, mamíferos terrestres, etc.

Além disto, a revisão do autor também trata dos modelos e das abordagens mais utilizadas nos estudos que foram cobertos, concluindo importantes fatos a respeito destes estudos, como a predominância das CNN's (Redes Neurais Convolucionais) nos modelos criados, utilizando a abordagem de transformar o áudio em um espectrograma. Dentre as CNN's, uma das principais abordagens utilizadas por uma parte significativa dos trabalhos foi a criação de uma arquitetura própria, porém, sua maioria utilizou o modelo ResNet. Também é levantada uma comparação a respeito das RNN's (Redes Neurais Recorrentes) com as CNN's, apoiando no fato de que RNN's conseguem lidar com dependências temporais longas, porém com uma performance inferior, o autor conclui que:

Uma RNN sozinha não costuma apresentar um bom desempenho. No entanto, por volta de 2017, observou-se que adicionar uma camada RNN após as camadas convolucionais de uma CNN poderia proporcionar um desempenho elevado em várias tarefas de áudio, com a interpretação de que as camadas RNN realizam uma integração temporal das informações previamente processadas pelas camadas iniciais. (Stowell, 2021, tradução nossa).

O autor cunha estes modelos convolucionais com camadas RNN embutidas como "CRNN's". Estas conclusões apresentadas, serão importantes para o desenvolvimento de uma metodologia adequada para este trabalho.

Sanchez et al. (2021) realizaram a detecção e classificação de sons bioacústicos utilizando como entrada de treinamento o sinal bruto dos áudios, sem a necessidade de extração prévia de atributos como espectrogramas ou coeficientes cepstrais, demonstrando a viabilidade de aplicar redes neurais diretamente sobre formas de onda em tarefas de monitoramento acústico passivo. Neste trabalho Sanchez et al. (2021) cita o termo "PAM" (Passive Acoustic Monitoring), ou monitoramento acústico passivo, essa prática se refere ao uso de dispositivos de gravação autônomos na natureza, para a captura de sons da fauna onde o objeto está localizado, para poder estudar o local, prática essa que já se demonstra superior do que a observação humana direta dos habitats das aves, trazendo assim uma importância significativa para o desenvolvimento de trabalhos que desenvolvem mais a eficiência do monitoramento do tipo PAM. (Darras et al., 2019).

Sanchez et al (2021) também menciona que uma das principais dificuldades do treinamento de modelos de machine learning é a obtenção de dados Strongly Labeled ou

fortemente nomeados, por isso o autor utilizou a base NIPS4Bplus que é amplamente conhecida no contexto de treinamento de modelos com bioacústica, contudo, diferentemente deste trabalho que busca extrair a própria base de dados.

Por fim neste trabalho o autor apenas conseguiu uma acurácia máxima de 75% nas classes e espécies relacionadas a aves, visto que o NIPS4Bplus tem sons de 1 espécie de anfíbio e 7 de insetos, que podem ser mais facilmente reconhecidos que aves, no entanto dificultando mais a identificação de apenas aves, visto que sons de pássaros tendem a ser mais semelhantes entre si, segundo o autor, a acurácia que, pode ser considerada relativamente baixa, estagnou nesse patamar devido à alta complexidade de dados, e também provavelmente devido à baixa quantidade de dados disponíveis e uma baixa minutagem.

Por fim, a importância desse artigo se dá ao uso de dados brutos de áudio pelo autor e à superação da chamada “maldição da dimensionalidade”, termo que se refere à dificuldade de aplicar algoritmos de aprendizado em dados com grande número de variáveis ou dimensões, o que tende a aumentar o custo computacional e reduzir a capacidade de generalização dos modelos.

Tradicionalmente, isso impedia o uso direto das formas de onda em tarefas de classificação bioacústica, exigindo etapas de transformação como espectrogramas e coeficientes cepstrais. Sanchez et al. (2021) superaram essa limitação utilizando a arquitetura SincNet, uma rede neural convolucional modificada que emprega filtros baseados em funções sinc na primeira camada, permitindo que o próprio modelo aprenda as frequências relevantes diretamente do sinal de áudio. Essa característica torna o treinamento mais eficiente e menos dependente de engenharia manual de atributos.

2.5.2. MLOps no Contexto da Bioacústica

Neste tópico desta fundamentação teórica, uma vez definidos os termos necessários, a importância do tema e trabalhos chave que aprimoram o desenvolvimento da monografia, por fim serão estudados trabalhos voltados à arquiteturas de MLOps voltados a bioacústica, explorando trabalhos importantes neste contexto e o seu estado da arte em 2025.

Villemez (2021) busca construir uma arquitetura completa de MLOps para um sistema de deep learning voltado a análise dos dados gerados por sensores acústicos passivos na detecção de embarcações. Estes sensores são cada vez mais presentes numerosos, juntamente com a quantidade de dados gerados, assim trazendo um desafio técnico, visto que

a quantidade de analistas humanos já não é suficiente para processar toda quantidade de dados gerada.

No processamento dos dados o autor aplica um *downsampling*, ou uma redução da taxa de amostragem dos dados acústicos, e depois também assim como outros autores já citados, os dados são transformados em espectrogramas, são aplicadas as *labels* e por fim são treinados em um modelo de Rede Neural Convolucional. Por fim, em seus resultados Villemez (2021) desenvolveu uma plataforma completa para o gerenciamento dos ciclos de vida do MLOps, permitindo monitorar o desempenho dos modelos, treinar novos modelos, comparar modelos e etc.

No entanto, a tese de Villemez (2021) não é sobre MLOps na bioacústica, pois não é focado na detecção de vida marinha, é importante destacar que mesmo após pesquisa, não são comuns artigos, teses e monografias sobre este tema ao pesquisar pelas palavras chave “MLOps” e “bioacústica” ou “bioacoustics”, neste sentido, esse trabalho acadêmico busca fomentar a presença destes temas e também preencher a lacuna existente do MLOps voltado para a bioacústica.

3. METODOLOGIA

3.1. BASE DE DADOS

Para iniciar o desenvolvimento deste trabalho, será fundamental a criação de uma base de dados organizada e sólida, visto que esta etapa é de importância primordial para a construção adequada de qualquer sistema de Inteligência Artificial, uma vez que a qualidade, a estrutura e a representatividade dos dados influenciam diretamente o desempenho dos modelos de aprendizado. A elaboração de um dataset consistente não se limita apenas à coleta dos áudios, mas envolve também processos de limpeza, padronização, categorização e armazenamento sistemático, garantindo que os dados estejam acessíveis e reproduzíveis ao longo de todo o ciclo de vida do modelo.

Além disso, uma base bem estruturada possibilita o emprego de práticas modernas de MLOps, como versionamento de dados, rastreabilidade de experimentos e monitoramento contínuo do desempenho dos modelos, assegurando escalabilidade e confiabilidade na experimentação científica. Dessa forma, a construção da base de dados não é uma simples etapa preliminar, mas sim o alicerce sobre o qual toda a metodologia deste trabalho será

desenvolvida, influenciando desde a escolha das abordagens de pré-processamento até as etapas de avaliação e manutenção dos modelos gerados

3.1.1. Extração dos dados

Como proposto inicialmente, e também no título desta monografia, os dados que serão utilizados para a criação desse sistema de IA e também a arquitetura de MLOps são os dados de acústica do WikiAves, não envolvendo sua parte de imagens, no entanto, o WikiAves não possui uma base de dados pública em um formato manipulável pronto para uso e limpeza, por isso nesta metodologia será necessária a extração dos dados através da metodologia de Web Scraping da plataforma do WikiAves.

O Web Scraping é a prática de extração de informações de um site, plataforma ou página web, e organizar estas em um documento de formato específico (Cambridge Dictionary, [s.d.]), neste caso, a prática de Web Scraping será necessária por navegar pela plataforma da WikiAves, explorar seus links e url's e encontrar diretamente em quais deles são dos sons disponíveis na plataforma, e assim realizar download de cada um dos itens.

Em um estudo breve da página da WikiAves e seu código fonte, através da ferramenta dos navegadores de “inspecionar elemento”, foi possível encontrar a url de origem do áudio disponível no site, como pode ser visto na Figura 2:

```

<div class="wa-grid-item wa-record-mobile" style="position: absolute; left: 0px; top: 0px;">
  <div class="m-portlet fadeInUp animated wa-record m-portlet--rounded wa-record-mobile wa-som" id="WA767919" hr
    wa-detalhes" grande="F">
    ::before
    <div class="wa-espec">...</div>
  <div class="wa-player progression-small2">
    <div class="responsive-wrapper responsive-audio">
      <div id="mep_0" class="mejs-container svg wikiaves-player progression-single progression-skin progression
        410.4px; height: 30px;">
        <div class="mejs-inner">
          <div class="mejs-mediaelement">
            <audio id="wa-player-767919" class="mejs-container svg wikiaves-player progression-single progressi
              dio" preload="none" src="https://s3.amazonaws.com/media.wikiaves.com.br/recordings/767/767919_65b86
            </div>
            <div class="mejs-layers">...</div>
            <div class="mejs-controls">...</div>
            <div class="mejs-clear"></div>
          </div>
        </div>
      </div>
    </div>
  </div>
  <script type="text/javascript">...</script>
  <div class="m-portlet__body wa-nowrap">...</div>
  ::after
</div>
</div>
<div class="wa-grid-item wa-record-mobile" style="position: absolute; left: 0px; top: 235.05px;">...</div>
<div class="wa-grid-item wa-record-mobile" style="position: absolute; left: 0px; top: 470.1px;">...</div>
<div class="wa-grid-item wa-record-mobile" style="position: absolute; left: 0px; top: 705.15px;">...</div>
<div class="wa-grid-item wa-record-mobile" style="position: absolute; left: 0px; top: 940.2px;">...</div>
<div class="wa-grid-item wa-record-mobile" style="position: absolute; left: 0px; top: 1175.25px;">...</div>
<div class="wa-grid-item wa-record-mobile" style="position: absolute; left: 0px; top: 1410.3px;">...</div>
<div class="wa-grid-item wa-record-mobile" style="position: absolute; left: 0px; top: 1645.35px;">...</div>
<div class="wa-grid-item wa-record-mobile" style="position: absolute; left: 0px; top: 1880.4px;">...</div>
<div class="wa-grid-item wa-record-mobile" style="position: absolute; left: 0px; top: 2115.45px;">...</div>
<div class="wa-grid-item wa-record-mobile" style="position: absolute; left: 0px; top: 2350.5px;">...</div>
<div class="wa-grid-item wa-record-mobile" style="position: absolute; left: 0px; top: 2585.55px;">...</div>
<div class="wa-grid-item wa-record-mobile" style="position: absolute; left: 0px; top: 2820.6px;">...</div>
<div class="wa-grid-item wa-record-mobile" style="position: absolute; left: 0px; top: 3055.65px;">...</div>
<div class="wa-grid-item wa-record-mobile" style="position: absolute; left: 0px; top: 3290.7px;">...</div>
<div class="wa-grid-item wa-record-mobile" style="position: absolute; left: 0px; top: 3525.75px;">...</div>
<div class="wa-grid-item wa-record-mobile" style="position: absolute; left: 0px; top: 3760.8px;">...</div>
<div class="wa-grid-item wa-record-mobile" style="position: absolute; left: 0px; top: 3995.85px;">...</div>

```

Figura 2: Código HTML da página do WikiAves com destaque nos arquivos de áudio.

Fonte: WikiAves(2025)

Na figura 2, podemos ver o código fonte da página de listagem de áudios da ave *Tinamus Solitarius*, ou macuco popularmente. No código, podemos ver as *div's* da classe “wa-grid-item” que são os containers onde estão os áudios na tela, no primeiro trecho do código há uma dessas *div's* expandidas com o foco na sua tag audio, sendo possível ver o link para um bucket da aws onde contém o áudio, sendo possível então, a partir desse link, fazer o download do áudio totalmente, como também de outros arquivos, como das imagens da ave, ou mesmo do espectrograma do áudio. Dessa forma, é possível concluir que é possível construir um algoritmo que seja capaz de extrair os dados da plataforma.

3.1.2. Análise e preparação dos dados

Uma vez com a base de dados já extraída, torna-se essencial realizar uma etapa cuidadosa de análise e preparação. Embora a fonte desses dados possua certo rigor teórico no processo de submissão, isso não garante que todas as amostras estejam adequadas para servir como material de treinamento em um modelo de aprendizado de máquina. Em bases bioacústicas especialmente grandes, como as derivadas de plataformas colaborativas, é comum encontrar gravações com ruídos excessivos, baixa qualidade, interrupções, sobreposição de espécies ou inconsistências decorrentes da própria natureza da coleta ambiental. Esses fatores podem comprometer a capacidade do modelo de aprender padrões relevantes e, conseqüentemente, afetar negativamente sua acurácia, estabilidade e poder de generalização.

Por essa razão, a etapa de preparação dos dados compreende operações fundamentais como verificação da integridade dos arquivos, uniformização de formatos, normalização da taxa de amostragem, remoção de trechos inutilizáveis, segmentação das gravações em janelas adequadas, identificação de outliers acústicos e avaliação preliminar da coerência entre as espécies rotuladas e os sons presentes, após esta preparação por fim os dados serão transformados em espectrogramas utilizando um STFT (Transformada de Fourier de Curto Tempo ou Short Time Fourier Transform) assim como Villemez (2021).

3.2. ARQUITETURA DO MODELO

3.2.1. Deep Learning é fundamental

A arquitetura de um modelo de ML é uma fase fundamental no processo de construção de uma ferramenta de IA eficiente, sendo o núcleo do desenvolvimento do aprendizado da IA. Baseado nas definições de Goodfellow, Bengio e Courville (2016), como já citado anteriormente, o Deep Learning é uma metodologia de ML que funciona através de neurônios alinhados em múltiplas camadas, assim essa arquitetura se mostra eficiente na detecção também de múltiplas camadas de complexidade de um problema.

O canto de um pássaro, pode ter fases e camadas de complexidade, variando em frequência, duração, múltiplas camadas de ciclos harmônicos, padrões temporais distintos e estruturas internas complexas que se combinam de formas diferentes de variadas, variando de espécie para espécie, ou até mesmo de macho para fêmea. Sendo assim, essas características

de hierarquia no som emitido por uma ave torna fundamental o uso de uma ferramenta de Deep Learning para a sua análise.

3.2.2. ResNet

A ResNet, inicialmente proposta por He et al. (2015), é uma arquitetura de rede neural visada para melhorar o desempenho de redes neurais muito profundas, com muitas camadas, sendo assim, a ResNet busca uma abordagem de aprendizado residual dentro das camadas de rede neural. Essa metodologia não aprende diretamente a função desejada da camada, e sim o que é definido por He et al. (2015) como o resíduo, sendo a diferença entre a entrada e a saída esperada: “Nós explicitamente reformulamos as camadas para que aprendam funções residuais com referência às entradas da própria camada, em vez de aprenderem funções sem referência.” (He et al. 2015).

No trabalho de Stowell (2021), foi concluído que dentro dos artigos acadêmicos estudados, a maioria aplicou também a ResNet para a identificação de bioacústica, demonstrando o crescente potencial desta arquitetura para a construção de modelos de DL neste nicho, sendo assim a arquitetura ResNet demonstra um potencial importante para o desenvolvimento deste trabalho, por isso foi escolhida como metodologia.

3.2.3. CRNN

Ainda no artigo de Stowell (2021), outra metodologia já citada neste documento, que volta a tona para ser aprofundada na metodologia, é o que o autor traz como CRNN, uma arquitetura de CNN combinada com uma camada de RNN. Convolutional Neural Network (CNN) ou Rede Neural Convolucional, é uma técnica de DL que se volta ao processamento de matrizes como entrada em uma Rede Neural, o RNN se traduz como Recurrent Neural Network ou Rede Neural Recorrente, e se volta para o processamento de dados sequenciais, sendo eficiente na captura de dados temporais em laços recorrentes na arquitetura dos dados, desta forma a metodologia de CRNN pode performar bons resultados combinada com a ResNet para esta proposta.

3.3. IMPLEMENTAÇÃO DA ARQUITETURA DE MLOPS

Para a construção de uma arquitetura de MLOps que atenda ao Nível 2 de Maturidade, é fundamental o desenvolvimento das características de CI/CD/CT (Continuous Integration, Continuous Delivery e Continuous Training), conforme delineado no modelo de maturidade do Google Cloud (2024). Atingir este patamar transcende a mera automação do treinamento, exigindo uma integração fluida e contínua entre as etapas de desenvolvimento, deploy e operação.

3.3.1. Treinamento Contínuo

Parte da espinha dorsal desta arquitetura será o Treinamento Contínuo (CT), concebido como um pipeline orquestrado e automatizado. Este pipeline será capaz de detectar a submissão de novos dados bioacústicos no repositório do WikiAves, acionando o fluxo de trabalho. As etapas iniciais incluem a ingestão e a validação rigorosa dos novos inputs, seguida pela aplicação do processamento de dados, que transforma os áudios em espectrogramas, servindo como features para o modelo de Deep Learning. A reexecução automatizada do treinamento com esta nova instância de dados é o que valida o Nível 1 de Maturidade do sistema de MLOps.

Essa etapa da arquitetura se ativa com um trigger que detecta a entrada de novos dados dentro do WikiAves dentro janela das aves que fazem parte do dataset, assim este dado novo será lido através do scrapping e processado para se adequar ao formato da base de dados. Após isso será armazenado dentro do DVC (Data Version Control), uma ferramenta de versionamento de base de dados para cientistas de dados (DVC, [s.d.]).

Para o re-treinamento do modelo, uma metodologia específica estará sendo abordada, visto que é inviável treinar o modelo toda vez que qualquer instância de dado for inserida no dataset, uma vez que dependente do escopo esse trigger tem o potencial disparar mais de uma vez por dia, para treinar todo um modelo que pode demorar mais de 24 horas para ser treinado. Por isso é importante a implementação de um *fine-tuning* do modelo, para que seja aprimorado apenas no contexto da instância do novo dado.

Uma vez então treinado o modelo, este será também armazenado e versionado através do MLFlow (s.d.), para que seja avaliado e por fim seja feito o seu deploy para “produção”.. Segue abaixo na figura 3 diagrama deste fluxo de treinamento contínuo:




Figura 3: Fluxo da arquitetura ao trigger de novo dado.

Fonte: autoria própria.

3.3.2. Experimentação do modelo

Além do gatilho de novos dados recebidos, outra automação que será realizada é a de alterações dentro da própria arquitetura do modelo. No documento do Google Cloud (2024), uma questão importante que é colocada sobre modelos de maturidade nível 2 do MLOps é a facilitação da experimentação pelo cientista de dados, sendo possível: “rapidamente novas ideias sobre engenharia de atributos, arquitetura de modelos e hiperparâmetros. É possível implementar essas ideias e criar, testar e implantar automaticamente os novos componentes do pipeline no ambiente de destino” (Google Cloud, 2024).

Contudo, a arquitetura proposta neste trabalho avança significativamente, pois o simples retreinamento do modelo ainda é uma implementação rudimentar e insuficiente para um sistema em produção. A transição para o Nível 2 exige a automação do deploy e, crucialmente, o versionamento sistemático de todos os artefatos envolvidos no ciclo de vida.

Para este avanço, outro gatilho criado dentro da arquitetura será de alteração do modelo e de seus hiperparâmetros. Uma vez modelado uma nova configuração de hiperparâmetros, imediatamente estes já são versionados no GitHub como “desenvolvimento”, e sequencialmente o modelo é treinado e também versionado no MLFlow (s.d.) também como “desenvolvimento”. Versionados o modelo e o código, a etapa deste fluxo segue para a validação, onde será avaliado pelo desenvolvedor, e por fim através disso o modelo pode ser enviado para “produção” assim finalizando este ciclo. Segue abaixo na figura 4 diagrama deste fluxo de experimentação do modelo:




Figura 4: Fluxo da arquitetura ao trigger de experimentação do modelo.

Fonte: autoria própria.

3.4. MONITORAMENTO E O FINAL DO CICLO DE VIDA DO MLOPS

O ciclo de vida de um modelo de Machine Learning não se encerra com o seu deploy em produção; pelo contrário, é neste ponto que se inicia a fase mais crítica e contínua do MLOps: o Monitoramento. Em um domínio dinâmico como o da bioacústica, onde as

condições ambientais, a qualidade das gravações e os padrões de vocalização das aves podem variar drasticamente, o monitoramento se estabelece como o baluarte contra a degradação do desempenho, um fenômeno conhecido como Model Drift ou Data Drift.

O módulo de monitoramento, conforme delineado no objetivo específico (d), é projetado para ser proativo e abrangente, garantindo a sustentabilidade do sistema. A vigilância contínua se concentra em três dimensões cruciais. Primeiramente, o Monitoramento de Desempenho (Performance Monitoring) envolve o acompanhamento em tempo real das métricas de domínio, como Acurácia, Precisão e Recall, cuja queda abaixo de um limiar de aceitação atua como o principal indicador de que o modelo está perdendo sua validade preditiva. Complementarmente, são monitoradas as métricas técnicas, como a latência de inferência, a taxa de erros e a utilização de recursos computacionais (CPU/GPU), essenciais para a saúde operacional do serviço.

Em segundo lugar, o Monitoramento de Dados (Data Drift) consiste na análise estatística contínua da distribuição das features de entrada (os espectrogramas) em produção, comparando-a com a dos dados de treinamento originais. Uma alteração significativa nesta distribuição sinaliza um Data Drift, indicando que o modelo está recebendo dados diferentes daqueles para os quais foi otimizado. Por fim, o Monitoramento de Conceito (Concept Drift) visa identificar mudanças na relação entre as features de entrada e a variável alvo. Embora mais sutil, a análise de erros de predição em subgrupos de dados ao longo do tempo pode indicar que o conceito aprendido pelo modelo não se sustenta mais na realidade atual, exigindo uma reavaliação.

O Final do Ciclo de Vida do MLOps é, na verdade, o seu reinício automatizado. Quando o monitoramento detecta uma degradação de desempenho (drift), um evento é gerado, que atua como o gatilho para o pipeline de Treinamento Contínuo (CT). Este ciclo de retroalimentação automatizado garante que o modelo seja re-treinado com os dados mais recentes e relevantes, gerando um novo artefato que é submetido a validação e, idealmente, a uma estratégia de Shadow Deployment (execução em paralelo com o modelo antigo) para uma validação final em produção. Somente após a comprovação de sua superioridade, o modelo campeão é promovido, substituindo o modelo anterior. Essa abordagem cíclica e automatizada é o que confere à arquitetura MLOps a robustez e a sustentabilidade necessárias para um sistema de bioacústica em produção, garantindo que o modelo se mantenha relevante e preciso diante da natureza volátil dos dados ambientais.

4. RESULTADOS ESPERADOS

A conclusão deste trabalho de pesquisa culminará na entrega de um conjunto de resultados que validam a proposta de uma arquitetura MLOps no domínio da bioacústica. Os resultados esperados estão intrinsecamente ligados aos objetivos específicos e às contribuições delineadas, e podem ser sumarizados em três eixos principais: a arquitetura, o modelo e a contribuição científica.

Espera-se a entrega de um protótipo funcional da arquitetura MLOps, implementado no Nível 2 de maturidade, conforme as delimitações do trabalho. Este protótipo deverá demonstrar a automação completa do ciclo de vida do modelo de bioacústica, desde a ingestão de dados até o deploy em produção. Um resultado crucial será o módulo de monitoramento integrado, capaz de detectar a degradação do modelo em tempo real e acionar o re-treinamento automático, comprovando o fechamento do ciclo MLOps. A avaliação da arquitetura será apresentada com métricas de eficiência e robustez do processo de operacionalização.

Será entregue uma base de dados de bioacústica de aves estruturada, resultante do WebScrapping da plataforma WikiAves. Esta base de dados servirá como insumo para o desenvolvimento de um modelo de Deep Learning para classificação de sons de aves. O resultado esperado para o modelo é a obtenção de uma acurácia e eficácia que demonstrem a viabilidade da abordagem proposta para o reconhecimento da avifauna brasileira, com uma análise detalhada do seu desempenho e potencial para aplicações futuras.

O trabalho resultará em uma contribuição significativa para a literatura de MLOps aplicada à bioacústica, preenchendo uma lacuna acadêmica identificada. Espera-se que a metodologia e a arquitetura propostas sirvam como referencial para o desenvolvimento de ferramentas de Machine Learning voltadas para a acústica de outros seres vivos. Por fim, o sistema desenvolvido e a base de dados criada, mesmo com as restrições de direitos autorais, deverão reforçar o potencial da Inteligência Artificial como aliada na conservação de espécies e no melhor entendimento da biodiversidade brasileira.

5. CRONOGRAMA

Quadro 2: Cronograma de execução das atividades.

2026							
Atividade	1	2	3	4	5	6	7
Extração dos dados	x						
Limpeza dos dados		x	x				
Estruturação do modelo			x	x			
Treinamento do modelo				x	x		
Implementação do MLOps					x		
Monitoramento do ciclo de vida do MLOps						x	
Análise dos Resultados							x
Documentação dos Resultados							x

REFERÊNCIAS

ANDERSON, M.; KENNEDY, J.; HARTE, N. Low Resource Species Agnostic Bird Activity Detection. 2021 IEEE Workshop on Signal Processing Systems (SiPS), p. 34–39, out. 2021. Acesso em: 22 nov 2025.

AXEL-CHRISTIAN GUEI et al. ECOGEN: Bird sounds generation using deep learning. *Methods in Ecology and Evolution*, 14 nov. 2023. Acesso em 22 nov 2025.

CAMBRIDGE DICTIONARY. Web Scraping. Cambridge University Press. Acesso em: 22 nov. 2025.

DALEFFI, B. Ecologia Acústica e Ciência de Dados: uma análise da paisagem sonora do cerrado: aplicabilidade e desempenho de modelos de aprendizado de máquina na identificação de formações ecológicas. 2024. Tese (Mestrado) – Escola Politécnica da Universidade de São Paulo, São Paulo, 2024. Acesso em: 11 nov. 2025.

DARRAS, K. et al.. Autonomous sound recording outperforms human observation for sampling birds: a systematic map and user guide. *Ecological Applications*, v. 29, n. 6, e01954, 2019. Acesso em: 18 nov. 2025.

DEEPMIND. How AI is helping advance the science of bioacoustics to save endangered species. Acesso em: 19 nov. 2025.

DVC. DVC.. Acesso em: 24 nov. 2025.

FEITOSA, L. A.; FÁTIMA, R. Critical Success Factors in Software Development Projects - A Systematic Literature Review. VIII Simpósio Internacional de Gestão de Projetos, Inovação e Sustentabilidade, 2 out. 2020. Acesso em: 16 nov. 2025.

GASC, A. et al. Assessing biodiversity with sound: Do acoustic diversity indices reflect phylogenetic and functional diversities of bird communities? *Ecological Indicators*, v. 25, p. 279–287, fev. 2013. Acesso em: 16 nov. 2025.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. Deep Learning. Cambridge: MIT Press, 2016. Acesso em: 17 nov. 2025.

GOOGLE CLOUD. MLOps: Continuous delivery and automation pipelines in machine learning. Google Cloud Architecture Center. Disponível em: <https://cloud.google.com/architecture/mlops-continuous-delivery-and-automation-pipelines-in-machine-learning>. Acesso em: 21 nov. 2025.

HOLDSWORTH, J.; SCAPICCHIO, M. . O que é Deep Learning ?. Disponível em: <https://www.ibm.com/br-pt/think/topics/deep-learning>. Acesso em: 14 nov. 2025.

IBM. Data Suggests Growth in Enterprise Adoption of AI is Due to Widespread Deployment by Early Adopters. Disponível em: <https://newsroom.ibm.com/2024-01-10-Data-Suggests-Growth-in-Enterprise-Adoption-of-AI-is-Due-to-Widespread-Deployment-by-Early-Adopters>. Acesso em: 13 nov. 2025.

KREUZBERGER, D.; KÜHL, N.; HIRSCHL, S. Machine Learning Operations (MLOps): Overview, Definition, and Architecture. arXiv, v. 3, 2022. Acesso em: 17 nov. 2025.

MLFlow. MLflow. Acesso em: 24 nov. 2025.

MERRIENBOER, B. V. et al. Perch 2.0: The Bittern Lesson for Bioacoustics. arXiv, v. 1, agosto de 2025.. Acesso em: 19 nov. 2025.

MITCHELL, T. M. Machine Learning. New York: McGraw-Hill, 1997. Acesso em: 10 nov. 2025.

MORFI, V.; BAS, Y.; PAMUŁA, H.; GLOTIN, H.; STOWELL, D. NIPS4Bplus: a richly annotated birdsong audio dataset. arXiv, 2018. Disponível em: <https://arxiv.org/abs/1811.02275>

. Acesso em: 12 nov. 2025.

MUCCI, Tim. What is technical debt?. IBM Think. Disponível em: <https://www.ibm.com/think/topics/technical-debt>

. Acesso em: 16 nov. 2025.

RUSSEL, Stuart J.; NORVIG, Peter. Artificial Intelligence: A Modern Approach. New Jersey: Pearson, 2021. Acesso em: 10 nov. 2025.

SANCHEZ, F. J. B. et al. Bioacoustic classification of avian calls from raw sound waveforms with an open-source deep learning architecture. Scientific Reports, v. 11, n. 15733, p. 1-12, 2021. Acesso em: 8 nov. 2025.

SCULLEY, D. et al. Hidden Technical Debt in Machine Learning Systems. Proceedings of the 28th Annual Conference on Neural Information Processing Systems , Montreal, Canadá, 2023. Acesso em: 17 nov. 2025.

SHARMA, S.; SATO, K.; GAUTAM, B. P.. A Methodological Literature Review of Acoustic Wildlife Monitoring Using Artificial Intelligence Tools and Techniques. Sustainability, v. 15. Acesso em: 16 nov. 2025.

STOWELL, D.; Computational bioacoustics with deep learning: a review and roadmap. PeerJ, Tilburg, v. 10, Dezembro, 2021. Acesso em: 21 nov 2025.

SUN, X. et al. Automatic classification of electrocardiogram signals based on transfer learning and continuous wavelet transform. Ecological Informatics, v. 69, p. 101628–101628, 1 jul. 2022. Acesso em 22 nov 2025.

TRINDADE, A. S. C.; OLIVEIRA, H. P. C. Inteligência Artificial(Ia) Generativa E Competência Em Informação Scielo, 2024. Acesso em: 13 nov. 2025.

VILLEMEZ, N. R. Machine Learning Operations (MLOPS) Architecture Considerations for Deep Learning with a Passive Acoustic Vector Sensor. Tese (Mestrado), Naval Postgraduate School, 2021. Disponível em: <https://apps.dtic.mil/sti/trecms/pdf/AD1165029.pdf>

. Acesso em: 21 nov. 2025

WIKIAVES. Como o WikiAves funciona. . Acesso em: 23 out. 2025.